

Đánh Giá Hiệu Quả Các Phương Pháp Khuyến Nghị Truyền Thống và Học Sâu trên Dữ Liệu Tương Tác Người Dùng–Món Ăn từ Nền Tảng Ẩm Thực Trực Tuyến Việt Nam

Sinh viên Thực hiện

Khoa Khoa học và Kỹ thuật Thông tin
Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
{24540011, 24540015, 24540034}@gm.uit.edu.vn

Abstract

Trên các nền tảng ẩm thực trực tuyến, hành vi đánh giá món ăn (rating) tạo thành dữ liệu tương tác người dùng có giá trị cho bài toán khai thác sở thích cá nhân. Nghiên cứu này sử dụng bộ dữ liệu ViFoodRec (Tran et al., 2024)—182.678 lượt tương tác người dùng–món ăn thu thập từ cộng đồng ẩm thực Việt Nam—để đánh giá thực nghiệm **bốn họ phương pháp khuyến nghị**: Content-Based Filtering (CBF), Memory-Based Collaborative Filtering (CF), Funk SVD và Neural Collaborative Filtering (NCF). Ba câu hỏi nghiên cứu được đặt ra: (RQ1) hiệu quả của CBF và CF trên dữ liệu tương tác MXH ẩm thực Việt; (RQ2) liệu Matrix Factorization và NCF có cải thiện dự đoán rating so với phương pháp truyền thống; (RQ3) mô hình nào phù hợp hơn cho Rating Prediction và Top- K Recommendation. Kết quả cho thấy NCF giảm RMSE xuống 1.5898 (thấp hơn User-CF 3.2%), trong khi User-CF (Cosine) đạt Precision@10 cao nhất (39.50%) dù chênh lệch giữa các mô hình ranking chỉ khoảng 1–2 điểm phần trăm. Nghiên cứu phân tích ý nghĩa thống kê, hạn chế và nguồn lỗi trên dữ liệu tương tác xã hội.

1 Giới thiệu

1.1 Bối cảnh: Khai thác dữ liệu tương tác trên nền tảng ẩm thực trực tuyến

Trên các diễn đàn và website ẩm thực (Monngon-moingay.com, Cooky.vn), người dùng không chỉ tiêu thụ nội dung công thức mà còn **phát sinh hành vi tương tác**: đánh giá món ăn, bình luận, lựa chọn theo sở thích cá nhân. Trong góc nhìn khai thác dữ liệu truyền thông xã hội, các rating này được xem là *implicit/explicit user-generated signals* phản ánh quan hệ người dùng–nội dung (user–item interaction), tương tự cơ chế “like/rating” trên mạng xã hội thương mại (Adomavicius and Tuzhilin, 2005). Việc mô hình hóa ma trận tương tác $R \in \mathbb{R}^{m \times n}$ nhằm dự đoán sở thích ẩn và gợi

ý nội dung phù hợp là bài toán cốt lõi của Recommendation Systems, đồng thời là ứng dụng trực tiếp của khai phá dữ liệu hành vi người dùng trên nền tảng số.

1.2 Vấn đề nghiên cứu

Mặc dù ViFoodRec (Tran et al., 2024) đã công bố bộ dữ liệu tương tác ẩm thực Việt Nam và đánh giá Content-Based cùng Memory-Based CF, **chưa có nghiên cứu nào làm rõ hiệu quả của các kỹ thuật Matrix Factorization và Deep Learning** trên cùng bối cảnh dữ liệu. Do đó, câu hỏi trung tâm của nghiên cứu này là:

RQ1 Các phương pháp Content-Based và Collaborative Filtering hoạt động như thế nào trên dữ liệu tương tác người dùng–món ăn ViFoodRec?

RQ2 Funk SVD và Neural CF có cải thiện chất lượng dự đoán rating so với các phương pháp dựa trên tương đồng tuyến tính (User-CF, Item-CF) hay không?

RQ3 Mô hình nào phù hợp hơn cho hai tác vụ *Rating Prediction* (regression) và *Top- K Recommendation* (ranking)?

1.3 Định nghĩa bài toán

Input: (i) Ma trận tương tác thưa $R = \{(u, i, r_{u,i})\}$, $r_{u,i} \in [0, 5]$; (ii) metadata món ăn A_i (nguyên liệu, mô tả, dinh dưỡng). **Output:** $\hat{r}_{u,i}$ (dự đoán rating) và danh sách Top- K món ăn chưa tương tác có $\hat{r}_{u,i}$ cao nhất.

1.4 Đóng góp nghiên cứu

- Phân tích đặc tính thống kê dữ liệu tương tác MXH ẩm thực Việt Nam và rút ra các *insight* ảnh hưởng tới thiết kế mô hình.
- Thiết kế thí nghiệm có thể tái lập (reproducible) so sánh 4 họ phương pháp trên cùng tập train/test.

3. Trả lời RQ1–RQ3 bằng 8 metrics, kèm thảo luận ý nghĩa thống kê thay vì chỉ liệt kê số liệu.
4. Phân tích lỗi có cấu trúc (nguyên nhân–biểu hiện–ảnh hưởng–hướng khắc phục) trên dữ liệu tương tác thực tế.

Cấu trúc báo cáo: Mục 2—công trình liên quan và khoảng trống nghiên cứu; Mục 3—dữ liệu và phân tích; Mục 4—phương pháp; Mục 5—thiết kế và kết quả thí nghiệm; Mục 6—thảo luận; Mục 7—phân tích lỗi; Mục 8—kết luận.

2 Công trình liên quan và Khoảng trống nghiên cứu

2.1 Khuyến nghị dựa trên nội dung (Content-Based)

CBF xây dựng hồ sơ món ăn từ thuộc tính văn bản và metadata, so khớp qua TF-IDF, Cosine, Jaccard hay BM25 (Lops et al., 2011; Tran et al., 2024). **Ưu điểm:** không phụ thuộc dữ liệu người dùng khác, phù hợp cold-start item. **Hạn chế:** overspecialization, khó nắm ngữ nghĩa sâu của công thức ẩm thực.

2.2 Khuyến nghị cộng tác (Collaborative Filtering)

CF khai thác **ma trận tương tác người dùng–món ăn**—dữ liệu hành vi cốt lõi trên nền tảng MXH ẩm thực (Sarwar et al., 2001). Memory-based CF gồm User-CF (tìm người dùng tương tự) và Item-CF (tìm món ăn tương tự) với Cosine hoặc Pearson. **Ưu điểm:** không cần metadata chi tiết. **Hạn chế:** sparsity, cold-start user/item.

2.3 Phân rã ma trận (Matrix Factorization)

Funk SVD biểu diễn người dùng và món ăn trong không gian nhân tố ẩn (latent factors), học qua SGD (Koren et al., 2009). Khác với CF memory-based, MF có khả năng tổng quát hóa qua các chiều ẩn biểu diễn sở thích (ví dụ: vị cay, thời gian nấu, dinh dưỡng) mà không cần khai báo trước.

2.4 Khuyến nghị nơ-ron (Neural Recommendation)

NCF (He et al., 2017) kết hợp user/item embedding với MLP để học tương tác **phi tuyến** giữa người dùng và món ăn. Đây là hướng tiếp cận hiện đại vượt khả năng mô hình hóa tuyến tính của CF truyền thống và MF thuần túy.

2.5 Khoảng trống nghiên cứu (Research Gap)

Bảng 1 tóm tắt vị trí của nghiên cứu hiện tại so với ViFoodRec gốc (Tran et al., 2024):

Mặc dù ViFoodRec đã đánh giá CBF và Memory-Based CF, **hiệu quả của Matrix Factorization và Deep Learning trên dữ liệu tương tác ẩm thực Việt Nam vẫn chưa được làm rõ**. Nghiên cứu này lấp khoảng trống đó, đồng thời trả lời RQ3 về sự phù hợp mô hình theo từng tác vụ.

3 Dữ liệu tương tác ViFoodRec

3.1 Nguồn dữ liệu

Nghiên cứu **sử dụng** bộ dữ liệu ViFoodRec đã công bố (Tran et al., 2024), thu thập từ các nền tảng ẩm thực trực tuyến Việt Nam (Mon-ngonmoingay.com, Cooky.vn). Bộ gồm: (i) `foods.csv`—metadata 4.000 món ăn, 16 thuộc tính; (ii) `ratings.csv`—182.678 lượt **tương tác đánh giá** từ 101 người dùng, thang [0.0, 5.0], bước 0.5. Ma trận tương tác có density 45.22%—tương đối dày so với các bộ dữ liệu thương mại điện tử thông thường (<5%).

3.2 Làm sạch và xây dựng đặc trưng

Làm sạch: Loại cặp (userId, foodId) trùng lặp (giữ bản ghi cuối); chuẩn hóa Unicode NFC; loại ký tự đặc biệt trên trường văn bản.

Xây dựng đặc trưng cho CBF: Ghép *ingredients + description + dish_tags* thành *combined_features*; vector hóa TF-IDF (*max_features* = 2000). Trọng số thuộc tính theo (Tran et al., 2024): *ingredients* (0.60), *description* (0.25), *dish_tags* (0.10), *nutrient_content* (0.05).

Chia dữ liệu: Ngẫu nhiên 90% train (164.410 tương tác), 10% test (18.268 tương tác), `random_state=42`.

3.3 Phân tích thống kê và insight

Hình 1 trình bày phân phối dữ liệu tương tác.

Insight 1 — Phân phối rating đồng đều: Hình 1 (trái) cho thấy tần suất rating phân bố tương đối **đồng đều** trên thang 0–5 ($\approx 9\%$ /mức). Khác với MovieLens hay Amazon (lệch về đánh giá cao), ViFoodRec giảm nguy cơ *positive class bias* trong huấn luyện, nhưng đồng thời làm **ranh giới “thích/không thích” bị nhòe**—một nguồn lỗi quan trọng (Mục 7).

Insight 2 — Ma trận dẹt (fat matrix): 101 người dùng $\times$ 4.000 món tạo ma trận “rộng”—ít hàng, nhiều cột. Điều này giải thích vì sao User-CF

Table 1: Khoảng trống nghiên cứu: ViFoodRec gốc so với nghiên cứu này

Khía cạnh	ViFoodRec (2024)	Nghiên cứu này
Dữ liệu tương tác MXH ẩm thực VN	Có (182K ratings)	Sử dụng Clean Dataset (4K món, 182K ratings)
Phương pháp truyền thống (CBF, Memory-CF)	Có (6+4 biến thể)	Có (TF-IDF, User/Item-CF)
Matrix Factorization (Funk SVD)	Chưa đánh giá	Có — trả lời RQ2
Deep Learning (NCF)	Chưa đánh giá	Có — trả lời RQ2
Thiết kế thí nghiệm tái lập	Một phần (200 mẫu test CF)	Train/test 90/10, 8 metrics
Thảo luận ý nghĩa thống kê	Hạn chế	Có — Mục 6




Figure 1: Phân phối rating, loại món ăn và mức hoạt động người dùng trên ViFoodRec.

(so sánh 101 vector) ổn định hơn Item-CF (so sánh 4.000 vector) trong kết quả thí nghiệm (Mục 5).

Insight 3 — Hoạt động người dùng tập trung: Phân phối số rating/user (Hình 1, phải) cho thấy phần lớn người dùng đánh giá >1.500 món, phản ánh tính chất dữ liệu được *thiết kế thu thập có chủ đích* trong ViFoodRec gốc, không phải log hành vi tự nhiên hoàn toàn ngẫu nhiên từ MXH.

4 Phương pháp luận

4.1 Content-Based Filtering (CBF)

CBF coi mỗi món ăn i là vector TF-IDF $\vec{V}_i$. Hồ sơ người dùng:

$$\vec{V}_u = \frac{\sum_{j \in I_u} r_{u,j} \cdot \vec{V}_j}{\sum_{j \in I_u} r_{u,j}}, \quad I_u = \{j : r_{u,j} \geq 3.5\} \quad (1)$$

Dự đoán: $\hat{r}_{u,i} = \text{Cosine}(\vec{V}_u, \vec{V}_i) \times 5.0$. CBF khai thác **metadata nội dung** từ nền tảng, không cần tương tác của user khác.

4.2 Memory-Based Collaborative Filtering

$$\text{User-CF: } \hat{r}_{u,i} = \bar{r}_u + \frac{\sum_{v \in N(u)} \text{sim}(u,v)(r_{v,i} - \bar{r}_v)}{\sum_v |\text{sim}(u,v)|}$$

$$\text{Item-CF: } \hat{r}_{u,i} = \frac{\sum_{j \in S(i)} \text{sim}(i,j) \cdot r_{u,j}}{\sum_j |\text{sim}(i,j)|}$$

CF trực tiếp khai thác **ma trận tương tác MXH** R ; $k = 15$ láng giềng, Cosine/Pearson.

4.3 Funk SVD (Matrix Factorization)

Mục tiêu: xấp xỉ $R \approx PQ^T$ với $P \in \mathbb{R}^{m \times f}$, $Q \in \mathbb{R}^{n \times f}$:

$$\hat{r}_{u,i} = \mu + b_u + b_i + P_u^T Q_i \quad (2)$$

Trong đó: μ —rating trung bình toàn cục; b_u, b_i —bias người dùng/món ăn (mức đánh giá trung bình lệch so với μ); P_u, Q_i —**embedding** biểu diễn sở thích ẩn (latent taste factors). Hàm mục tiêu:

$$\min_{P, Q, b} \sum_{(u,i) \in \mathcal{K}} (r_{u,i} - \hat{r}_{u,i})^2 + \lambda(\|P_u\|^2 + \|Q_i\|^2 + b_u^2 + b_i^2) \quad (3)$$

Tối ưu bằng **SGD** từng mẫu (u, i, r) trong tập train $\mathcal{K}$.

4.4 Neural Collaborative Filtering (NCF)

NCF ánh xạ u, i sang embedding $e_u, e_i \in \mathbb{R}^d$, nói $[e_u; e_i]$ qua MLP:

$$\hat{r}_{u,i} = W_L \cdot \phi_L(\dots \phi_1(W_1[e_u; e_i] + b_1) \dots) + b_L \quad (4)$$

Khác SVD (tuyến tính trên dot-product), MLP học **hàm tương tác phi tuyến**—phù hợp khi sở thích người dùng với món ăn không thể biểu diễn bằng tích vô hướng đơn giản. Triển khai bằng MLP scikit-learn (fallback khi PyTorch không khả dụng); loss MSE, optimizer Adam.

4.5 Độ đo đánh giá

Rating Prediction: MSE, RMSE, MAE, NMAE (= MAE/5). **Top- K Ranking:** Precision@10,

Recall@10, NDCG@10, MRR; relevance nếu $r_{u,i} \geq 3.5$.

5 Thiết kế thí nghiệm và Kết quả

5.1 Thiết lập thí nghiệm (Experimental Setup)

Bảng 2 liệt kê cấu hình để đảm bảo tái lập kết quả:

5.2 Kết quả theo từng phương pháp

Phương pháp 1 — CBF (Bảng 3): RMSE=1.9502 cao nhất, xác nhận CBF kém trong dự đoán rating khi chỉ dựa metadata văn bản.

Phương pháp 2 — CF (Bảng 4): User-CF (Cosine) tốt nhất ranking; Item-CF (Cosine) tốt nhất MAE (1.4016).

Phương pháp 3 — Funk SVD (Bảng 5): RMSE=1.6467, cải thiện so với User-CF về MAE tương đương.

Phương pháp 4 — NCF (Bảng 6): RMSE=1.5898 thấp nhất; MRR=62.30% cao nhất.

5.3 Bảng tổng hợp

6 Thảo luận kết quả

6.1 Trả lời RQ1: CBF và CF trên dữ liệu tương tác ViFoodRec

CF vượt trội CBF trên mọi metric regression (RMSE giảm $\approx 18\%$). Điều này phù hợp lý thuyết: trên dữ liệu tương tác MXH dày đặc (density 45%), **hành vi người dùng** mang thông tin dự đoán mạnh hơn metadata văn bản. CBF vẫn có vai trò hỗ trợ khi thiếu tương tác (cold-start item).

6.2 Trả lời RQ2: MF và NCF so với phương pháp truyền thống

NCF giảm RMSE từ 1.6429 (User-CF) xuống 1.5898 ($\Delta \approx 0.053$, tương đương **3.2%**), MAE từ 1.4087 xuống 1.3763. Funk SVD cải thiện khiêm tốn so với CF. **Giải thích:** kiến trúc MLP của NCF học được tương tác phi tuyến giữa embedding người dùng và món ăn—ví dụ, người dùng thích món cay và nhanh có thể không được biểu diễn tốt bởi dot-product tuyến tính $P_u^T Q_i$. Tuy nhiên, mức cải thiện tuyệt đối nhỏ, cho thấy **dữ liệu tương tác ViFoodRec** đã khá “dễ” cho các mô hình tuyến tính.

6.3 Trả lời RQ3: Mô hình theo tác vụ

- **Rating Prediction:** NCF (RMSE=1.5898, MAE=1.3763).

- **Top- K Ranking (P@10, NDCG):** User-CF Cosine (39.50%, 39.92%).

- **MRR:** NCF (62.30%)—mô hình đặt món relevant đầu tiên sớm hơn.

Không tồn tại mô hình “tốt nhất tuyệt đối”; lựa chọn phụ thuộc tác vụ triển khai.

6.4 Thảo luận ý nghĩa thống kê

Precision@10 dao động 35.54%–39.50%—chênh lệch tối đa **4 điểm phần trăm**. User-CF dẫn đầu ranking nhưng NCF thua 4% P@10 dù thắng RMSE. Điều này cho thấy **optimize regression $\neq$ optimize ranking** trên ViFoodRec: tối ưu sai số bình phương không đảm bảo thứ hạng Top- K tốt hơn. Mức Precision ≈ 37 –40% phản ánh độ khó của bài toán khi ranh giới relevance (rating ≥ 3.5) bị nhòe do phân phối rating đồng đều (Insight 1, Mục 3).

6.5 Ý nghĩa đối với khai thác dữ liệu MXH

Nghiên cứu chứng minh rằng **dữ liệu tương tác người dùng trên nền tảng ẩm thực trực tuyến** có thể được khai thác hiệu quả bằng CF và mô hình học sâu để mô hình hóa sở thích. Tuy nhiên, đặc tính thống kê của ViFoodRec (density cao, rating đồng đều, ma trận dẹt) tạo **bối cảnh thí nghiệm riêng**, cần thận trọng khi khái quát hóa sang log hành vi MXH tự nhiên.

7 Phân tích lỗi đa khía cạnh

7.1 Cold-Start (Người dùng/Món ăn mới)

Nguyên nhân: Thiếu hàng/cột trong ma trận R . **Biểu hiện:** CF/SVD/NCF dự đoán $\approx \mu = 2.5$. **Ảnh hưởng:** Bỏ sót món tiềm năng; RMSE tăng trên cặp hiếm. **Hướng khắc phục:** Hybrid CBF+NCF; side information từ metadata.

7.2 Popularity Bias (Thiên lệch phổ biến)

Nguyên nhân: Món có nhiều rating (phở, cơm tấm) chiếm ưu thế trong hàm mục tiêu. **Biểu hiện:** Top- K lặp lại món phổ biến. **Ảnh hưởng:** Giảm đa dạng, cá nhân hóa kém. **Hướng khắc phục:** Re-ranking với penalty popularity; explore-exploit.

7.3 Sparsity và cấu trúc ma trận dẹt

Nguyên nhân: 101 users vs 4.000 items. **Biểu hiện:** Item-CF kém ổn định hơn User-CF. **Ảnh hưởng:** Item-based gợi ý không tin cậy. **Hướng khắc phục:** Ưu tiên User-CF hoặc MF trên ma trận dẹt.

Table 2: Cấu hình thí nghiệm (Experimental Setup)

Thành phần	Cấu hình
Hệ điều hành	Windows 10
CPU / RAM	Intel x64, 8 GB RAM (giới hạn bộ nhớ)
Python	3.12+
Thư viện	scikit-learn 1.3+, NumPy, Pandas, PyTorch (fallback MLP nếu OOM)
Chia dữ liệu	Train 90% / Test 10%, random_state=42
CBF	TF-IDF max_features=2000, Cosine similarity
Memory-CF	$k = 15$ neighbors, Cosine & Pearson
Funk SVD	$f = 10$ latent factors, lr=0.01, $\lambda = 0.02$, epochs=8, SGD
NCF (MLP)	hidden=(16,), Adam lr=0.001, max_iter=20, batch=512, early_stopping
Ngưỡng relevance	rating ≥ 3.5 ; Top- $K=10$

Table 3: Kết quả Content-Based Filtering (trả lời RQ1)

Regression					Ranking			
CBF (TF-IDF)	3.8035	1.9502	1.6100	0.3220	36.93%	5.58%	36.70%	56.90%

7.4 Nhiễu văn bản (Text Noise)

Nguyên nhân: TF-IDF chỉ so khớp từ vựng. **Biểu hiện:** CBF RMSE cao nhất (1.95). **Ảnh hưởng:** Gợi ý theo nội dung kém chính xác. **Hướng khắc phục:** PhoBERT/Sentence Transformers cho tiếng Việt.

7.5 Mơ hồ hóa rating (Rating Ambiguity)

Nguyên nhân: Phân phối rating đồng đều 0–5 (Insight 1). **Biểu hiện:** Ngưỡng 3.5 không phân tách rõ “thích/không thích”. **Ảnh hưởng:** Precision@10 thấp (≈ 37 –40%). **Hướng khắc phục:** Thu thập dữ liệu tương tác tự nhiên hơn từ MXH thực; implicit feedback (view, save, share).

8 Kết luận

(1) Mục tiêu: Đánh giá hiệu quả bốn họ phương pháp khuyến nghị trên dữ liệu tương tác người dùng–món ăn ViFoodRec, trả lời RQ1–RQ3.

(2) Phương pháp: Thiết kế thí nghiệm tái lập với 8 metrics, 4 phương pháp (CBF, CF, Funk SVD, NCF), train/test 90/10.

(3) Kết quả chính: NCF tốt nhất Rating Prediction (RMSE=1.5898); User-CF Cosine tốt nhất Top- K (P@10=39.50%); chênh lệch ranking giữa mô hình chỉ 1–4%.

(4) Ý nghĩa học thuật: Dữ liệu tương tác MXH ẩm thực VN có thể khai thác bằng CF và DL; MF/NCF cải thiện regression nhưng không thống trị ranking; đặc tính thống kê ViFoodRec (density cao, rating đồng đều) ảnh hưởng trực tiếp tới hiệu năng và cách diễn giải kết quả.

(5) Hạn chế: Sử dụng dataset có sẵn (không thu thập mới); NCF triển khai MLP fallback do giới

hạn tài nguyên; chưa kiểm định ý nghĩa thống kê (significance test).

(6) Hướng phát triển: Hybrid recommender; embedding ngữ nghĩa tiếng Việt; thu thập implicit feedback từ MXH thực; tích hợp ràng buộc dinh dưỡng.

Ứng dụng demo Streamlit được triển khai phục vụ minh họa pipeline khai thác, không phải đóng góp khoa học trung tâm.

A Mô tả thuộc tính dữ liệu

References

- Gediminas Adomavicius and Alexander Tuzhilin. 2005. Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6):734–749.
- Xiangnan He, Lizi Liao, Hanwang Zhang, Xia Nie, Liqiang Hu, and Tat-Seng Chua. 2017. Neural collaborative filtering. In *Proceedings of the 26th International Conference on World Wide Web*, pages 173–182.
- Yehuda Koren, Robert Bell, and Chris Volinsky. 2009. Matrix factorization techniques for recommender systems. *Computer*, 42(8):30–37.
- Pasquale Lops, Marco De Gemmis, and Giovanni Semeraro. 2011. Content-based recommender systems: State of the art and trends. *Recommender Systems Handbook*, pages 73–105.
- Badrul Sarwar, George Karypis, Joseph Konstan, and John Riedl. 2001. Item-based collaborative filtering recommendation algorithms. In *Proceedings of the 10th International Conference on World Wide Web*, pages 285–295.

Table 4: Kết quả Collaborative Filtering (trả lời RQ1)

	Regression				Ranking			
User-CF (Cosine)	2.6990	1.6429	1.4087	0.2817	39.50%	5.99%	39.92%	59.92%
User-CF (Pearson)	2.7588	1.6610	1.4195	0.2839	38.61%	5.81%	38.50%	58.63%
Item-CF (Cosine)	2.6509	1.6282	1.4016	0.2803	38.51%	5.83%	38.27%	60.47%
Item-CF (Pearson)	2.6910	1.6404	1.4088	0.2818	37.23%	5.61%	37.67%	59.18%

Table 5: Kết quả Funk SVD (trả lời RQ2)

Funk SVD ($f=10$)	2.7118	1.6467	1.4141	0.2828	37.72%	5.68%	37.62%	57.47%
---------------------	--------	--------	--------	--------	--------	-------	--------	--------

Huynh-Quoc An Tran, Hong Thi-Thuy Dang, Thanh Chi Dang, and Tin Van Huynh. 2024. A new dataset and empirical evaluation for vietnamese food recommendation system. In *Proceedings of the Pacific Asia Conference on Language, Information and Computation (PACLIC)*.

Table 6: Kết quả Neural CF (trả lời RQ2, RQ3)

NCF (MLP)	2.5276	1.5898	1.3763	0.2753	35.54%	5.36%	36.69%	62.30%
-----------	---------------	---------------	---------------	---------------	--------	-------	--------	---------------

Table 7: So sánh tổng hợp — trả lời RQ3

Mô hình	MSE	RMSE	MAE	NMAE	P@10	R@10	NDCG	MRR
Content-Based	3.8035	1.9502	1.6100	0.3220	36.93%	5.58%	36.70%	56.90%
User-CF (Cosine)	2.6990	1.6429	1.4087	0.2817	39.50%	5.99%	39.92%	59.92%
Item-CF (Cosine)	2.6509	1.6282	1.4016	0.2803	38.51%	5.83%	38.27%	60.47%
Funk SVD	2.7118	1.6467	1.4141	0.2828	37.72%	5.68%	37.62%	57.47%
Neural CF	2.5276	1.5898	1.3763	0.2753	35.54%	5.36%	36.69%	62.30%




Figure 2: So sánh trực quan RMSE/MAE (trái) và Precision@10/NDCG@10 (phải).

Table 8: Mô tả các thuộc tính trong bộ dữ liệu ViFoodRec (theo Tran et al., 2024)

File	Thuộc tính	Mô tả
foods.csv	food_id	Mã định danh món ăn
	dish_name	Tên món ăn
	description	Mô tả ngắn gọn
	ingredients	Danh sách nguyên liệu
	cooking_method	Hướng dẫn chế biến
	dish_type	Phân loại (mặn/chay/...)
	serving_size	Số người phục vụ
	cooking_time	Thời gian nấu (phút)
	calories, protein, fat, sugar, fiber	Thông tin dinh dưỡng
	dish_tags	Từ khóa món ăn
ratings.csv	userId, foodId, rating	Người dùng, món ăn, điểm [0–5] (tương tác MXH)